

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Duy Vũ
Nguyễn Chiêu Bản

HỆ THỐNG GỢI Ý SẢN PHẨM
DỰA TRÊN MÔ HÌNH HỌC NHÂN QUẢ

KHÓA LUẬN ĐẠI HỌC KHOA HỌC MÁY TÍNH

Tp. Hồ Chí Minh, tháng 06/2022

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Duy Vũ - 18120264
Nguyễn Chiêu Bản - 18120283

**HỆ THỐNG GỢI Ý SẢN PHẨM
DỰA TRÊN MÔ HÌNH HỌC NHÂN QUẢ**

KHÓA LUẬN ĐẠI HỌC KHOA HỌC MÁY TÍNH
NGƯỜI HƯỚNG DẪN

Th.S. Trần Trung Kiên

TS. Nguyễn Ngọc Thảo

Tp. Hồ Chí Minh, tháng 06/2022

Lời cảm ơn

Tôi xin chân thành cảm ơn ...

Mục lục

Lời cảm ơn	i
Đề cương chi tiết	ii
Mục lục	ii
Tóm tắt	v
1 Giới thiệu	1
1.1 Phát biểu và ý nghĩa của bài toán	1
1.2 Thách thức của bài toán	3
1.3 Tổng quan	7
2 Kiến thức nền tảng	9
2.1 “Matrix factorization”	9
2.2 “Gradient descent”	11
2.3 “Naive bayes”	11
2.4 “Logistic regression”	11
3 Phương pháp tìm hiểu	12
3.1 Xem hệ thống gợi ý như một điều trị	12
3.2 “Inverse propensity scoring” (IPS)	15
3.3 “Self normalized inverse propensity scoring” (SNIPS)	17
3.4 Ước lượng ma trận xu hướng	17
3.4.1 Ước lượng ma trận xu hướng thông qua Naive bayes	19

3.4.2	Ước lượng ma trận xu hướng thông qua Logistic regression	20
3.5	Phân rã ma trận kết hợp với IPS	20
4	Các kết quả thí nghiệm	21
4.1	Các thiết lập thí nghiệm	22
4.2	Đánh giá các phương pháp ước lượng điểm xu hướng . . .	22
4.3	Đánh giá các phương pháp phân rã ma trận	22
4.4	Đánh giá hiệu suất trên dữ liệu thế giới thực	22
5	Tổng kết và hướng phát triển	23
	Tài liệu tham khảo	24

Danh sách hình

1.1	Cách thức hoạt động của hệ thống đề xuất sản phẩm . . .	2
1.2	Phân phối điểm đánh giá sản phẩm được chọn ngẫu nhiên và do người dùng chọn.	4
1.3	Ví dụ minh họa tác động của thiên lệch dữ liệu. Y là những con số nằm bên dưới ma trận. O là những điểm đánh giá của người dùng cho các sản phẩm. \hat{Y} là những điểm đánh giá được tô màu.	5
1.4	Các cách dự đoán \hat{Y}_1 và \hat{Y}_2 trên tập dữ liệu	6
1.5	Đánh giá 2 mô hình dự đoán \hat{Y}_1, \hat{Y}_2 dựa trên các mâu quan sát được	7
2.1	Matrix Factorization. Ma trận tương tác R sẽ được phân rã thành ma trận đại diện cho người dùng P và đại diện cho sản phẩm Q	10

Danh sách bảng

Chương 1

Giới thiệu

Trong chương này, đầu tiên nhóm chúng em phát biểu về bài toán đề xuất sản phẩm cũng như là ý nghĩa của nó đối với cuộc sống hiện nay. Sau đó, nhóm chúng em trình bày về vấn đề thiên lệch dữ liệu, một thách thức lớn của bài toán đề xuất sản phẩm. Từ đó dẫn đến phương pháp nhóm chúng em tìm hiểu “Inverse propensity scoring” (IPS) để khắc phục vấn đề thiên lệch dữ liệu này. Ngoài ra, ở cuối chương nhóm chúng em sẽ trình bày về cách tổ chức của khóa luận.

1.1 Phát biểu và ý nghĩa của bài toán


Ngày nay, với sự phát triển của công nghệ thông tin ngày càng sinh ra rất nhiều loại sản phẩm khác nhau. Điều này tạo nên thách thức cho người dùng là làm thế nào để có thể tìm thấy được các sản phẩm phù hợp với bản thân giữa một lượng sản phẩm khổng lồ như vậy. Do đó hệ thống đề xuất sản phẩm đã ra đời nhằm mục đích hỗ trợ cho người dùng trong quá trình tìm kiếm nội dung phù hợp cho bản thân..

Các hệ thống đề xuất sản phẩm giúp cho trải nghiệm của người dùng được cá nhân hóa, giúp tiết kiệm thời gian cho người dùng trong việc lựa chọn sản phẩm. Mặt khác, đối với các công ty nó còn tăng cao lợi thế cạnh tranh, kích thích nhu cầu mua sắm của người dùng bằng các gợi ý

sản phẩm. Có thể kể đến các hệ thống đề xuất sản phẩm nổi tiếng như: hệ thống đề xuất phim của Netflix, hay hệ thống đề xuất video của Youtube, hệ thống đề xuất nhạc của Spotify và nhiều loại hệ thống đề xuất khác nữa.

Bài toán hệ thống đề xuất sản phẩm sẽ được phát biểu như sau (minh họa ở hình 1.1):

- Đầu vào là dữ liệu về điểm đánh giá của các người dùng đối với các sản phẩm trong hệ thống (ngoài ra, còn có thể có thêm dữ liệu về thông tin của mỗi người dùng và mỗi sản phẩm).
- Yêu cầu: đề xuất các sản phẩm trong hệ thống mà phù hợp với sở thích của mỗi người dùng (để có thể đề xuất thì một cách làm phổ biến là dự đoán điểm đánh giá của người dùng đối với các sản phẩm mà người dùng chưa đánh giá).



Hình 1.1: Cách thức hoạt động của hệ thống đề xuất sản phẩm

Trong phạm vi đề tài của khóa luận nhóm chúng em sẽ tiến hành xử lý trên dữ liệu explicit feedback. Explicit feedback là dữ liệu cho biết rõ ràng


mức độ ưa thích của người dùng đối với sản phẩm, chẳng hạn như điểm đánh giá của người dùng cho 1 bộ phim từ 1 đến 5.

1.2 Thách thức của bài toán


Để huấn luyện được mô hình có thể đề xuất chính xác tất cả các sản phẩm cho người dùng, ta cần một bộ dữ liệu đầy đủ bao gồm đánh giá của tất cả người dùng cho tất cả sản phẩm. Tuy nhiên dữ liệu này không thể có được trong thực tế, do người dùng không thể nào xem và đánh giá tất cả các sản phẩm trong hệ thống. Vì vậy để mô hình có thể huấn luyện được tốt nhất ta cần bộ dữ liệu quan sát được phải được phát sinh từ phân phối đều của bộ dữ liệu đầy đủ này, vì bộ dữ liệu quan sát được này sẽ phản ánh được phần nào bộ dữ liệu đầy đủ và nó được gọi là dữ liệu không bị thiên lệch.

Dữ liệu quan sát được trong bài toán đề xuất sản phẩm thường bị gặp vấn đề lớn về thiên lệch dữ liệu. Thiên lệch dữ liệu: Dữ liệu quan sát được không được phát sinh từ phân phối đều, do đó nó không phản ánh được phần nào bộ dữ liệu đầy đủ. Bắt nguồn từ 2 nguyên nhân chính trong việc thu thập dữ liệu sau:

- Do người dùng tự chọn các bộ phim để đánh giá, thay vì dựa trên việc người dùng đánh giá một tập các sản phẩm ngẫu nhiên, việc người dùng đánh giá trên một tập các sản phẩm ngẫu nhiên để đảm bảo tính độc lập và phân phối giống nhau của dữ liệu. Một kết quả nghiên cứu của tác giả Marlin và các cộng sự [15] đã cho thấy tác động rõ ràng của thiên lệch dữ liệu. Họ đã tiến hành một cuộc khảo sát người dùng để thu thập dữ liệu điểm đánh giá của người dùng đối với một số sản phẩm được lựa chọn ngẫu nhiên, để so sánh với các sản phẩm do người dùng tự lựa chọn. Hình 1.2 đã cho thấy rõ sự khác nhau trong phân phối dữ liệu của việc lựa chọn ngẫu nhiên và do người dùng đánh giá và đưa ra 2 phát hiện: 1) người dùng có xu



(a) Các sản phẩm được chọn ngẫu nhiên.



(b) Các sản phẩm được chọn do người dùng.

Hình 1.2: Phân phối điểm đánh giá sản phẩm được chọn ngẫu nhiên và do người dùng chọn.

hướng chọn và đánh giá các mặt hàng họ thích; và 2) người dùng có nhiều khả năng xếp hạng các mặt hàng đặc biệt xấu hoặc đặc biệt tốt.

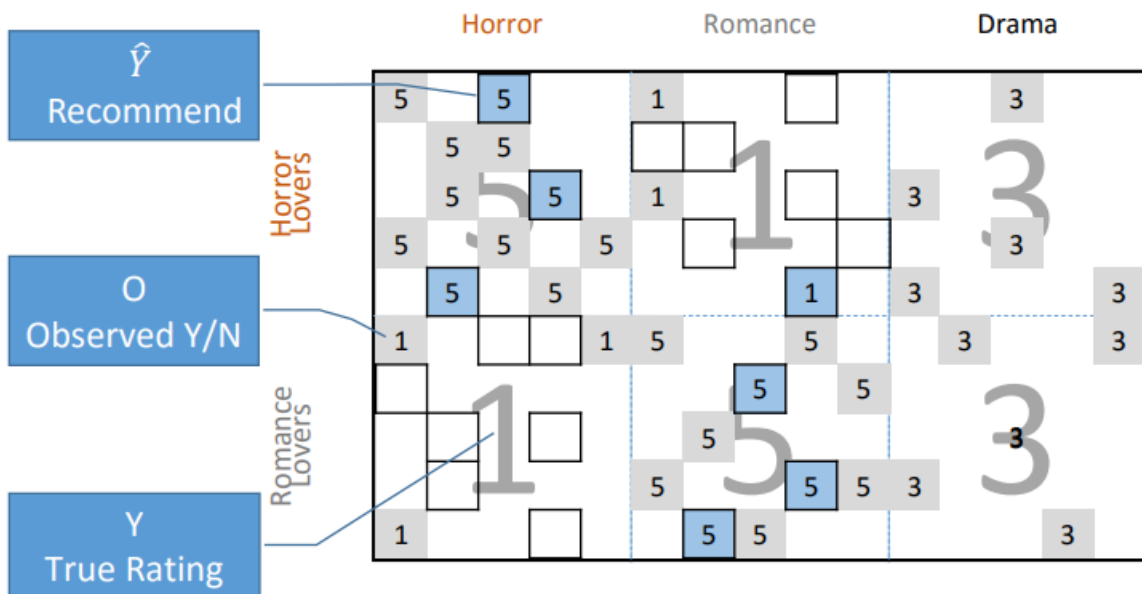
- Do hệ thống đề xuất chỉ chọn các bộ phim nào đó để hiển thị cho người dùng, trong trường hợp hệ thống đề xuất sản phẩm đã triển khai từ trước. Với tác động của hệ thống đề xuất như vậy, người dùng chỉ có thể xem và đánh giá trên các bộ phim được hiển thị, điều này làm cho dữ liệu thu thập được chỉ tập trung vào một vài loại sản phẩm nào đó, không đại diện cho toàn bộ dữ liệu.

Để hiểu rõ hơn về vấn đề thiên lệch dữ liệu ta sẽ xem xét một ví dụ nhỏ trong hệ thống đề xuất phim, minh họa tác động của thiên lệch dữ liệu có thể gây ra cho việc đánh giá mô hình. Hình 1.3 minh họa cho thí nghiệm của ta trong đó:

- Ma trận Y là ma trận đầy đủ chứa đánh giá của tất cả người dùng đối với tất cả các sản phẩm, trong ma trận này bao gồm 2 nhóm nhỏ: 1) những người dùng yêu thích phim kinh dị, họ sẽ đánh giá 5 điểm cho tất cả các phim kinh dị và 1 điểm cho tất cả các phim lãng

mãn mà họ đã xem; nhóm trái ngược 2) những người dùng yêu thích phim lãng mạn, họ sẽ đánh giá 1 điểm cho tất cả các phim kinh dị và 5 điểm cho tất cả các phim lãng mạn mà họ đã xem; và cả 2 nhóm người dùng đều đánh giá cho thể loại phim kịch là 3.

- Ma trận \hat{Y} là ma trận đại diện cho điểm đánh giá dự đoán của mô hình chúng ta xem xét.
- Ma trận O là ma trận nhị phân chứa 2 giá trị 0 và 1, đại diện cho những sản phẩm người dùng đã đánh giá trong hệ thống, $[O_{u,i} = 1] \Leftrightarrow [Y_{u,i} \text{ được quan sát}]$.

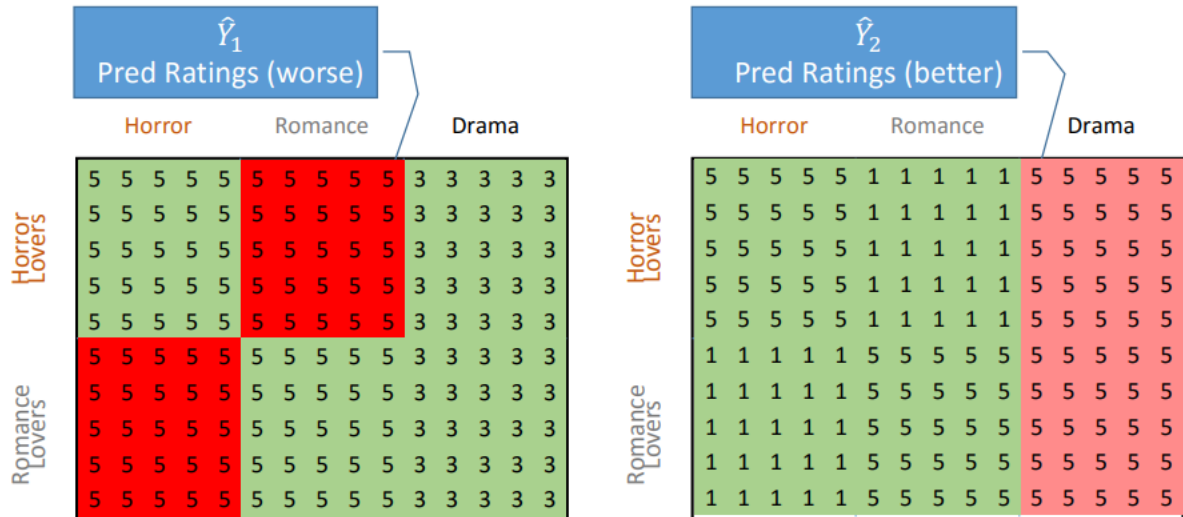


Hình 1.3: Ví dụ minh họa tác động của thiên lệch dữ liệu. Y là những con số nằm bên dưới ma trận. O là những điểm đánh giá của người dùng cho các sản phẩm. \hat{Y} là những điểm đánh giá được tô màu.

Các dự đoán \hat{Y}_1 và \hat{Y}_2 sẽ được dùng để dự đoán giá trị cho các điểm đánh giá chưa quan sát được. Hình 1.4 sẽ minh họa cách 2 mô hình dự đoán như sau:

- Ở cách dự đoán \hat{Y}_1 , những điểm đánh giá có giá trị thật là 1 sẽ được dự đoán là 5, các điểm đánh giá có giá trị thật là 3 và 5 sẽ được dự đoán đúng giá trị.

- Ở cách dự đoán \hat{Y}_2 , những điểm đánh giá có giá trị thật là 3 sẽ được dự đoán là 5, các điểm đánh giá có giá trị thật là 3 và 5 sẽ được dự đoán đúng giá trị.



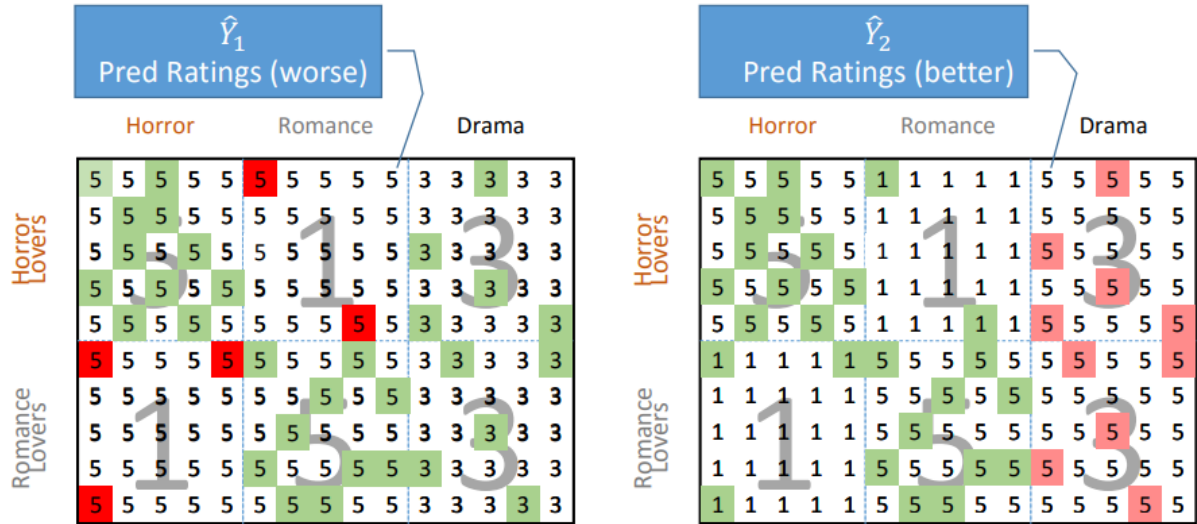
Hình 1.4: Các cách dự đoán \hat{Y}_1 và \hat{Y}_2 trên tập dữ liệu

Nếu chúng ta có thể quan sát toàn bộ dữ liệu như trong hình 1.4, ta có thể thấy với cách dự đoán \hat{Y}_1 khi giá trị thật là 1 nhưng dự đoán là 5 thì độ lỗi của nó rất lớn. Khi so với cách dự đoán \hat{Y}_2 khi giá trị thật là 3 và dự đoán là 5 có độ lỗi không quá nghiêm trọng như cách dự đoán \hat{Y}_1 .

Để đánh giá một cách dự đoán có tốt hay không, ta sẽ tiến hành đánh giá độ lỗi trên tập dữ liệu quan sát được. Tuy nhiên dữ liệu quan sát được ở đây lại không được phát sinh từ phân phối đều do đó nó có sự thiên lệch, cụ thể hơn là những điểm đánh giá là 1 xuất hiện ít hơn những điểm đánh giá là 3 (minh họa ở hình 1.5); điều này bắt nguồn từ việc người dùng tự lựa chọn các bộ phim họ thích để đánh giá.

Khi đánh giá cách dự đoán nào là tốt trên tập dữ liệu quan sát được bị thiên lệch này, ta sẽ cho rằng dự đoán \hat{Y}_1 tốt hơn \hat{Y}_2 . Vì theo cách dự đoán \hat{Y}_1 những điểm có độ lỗi lớn (điểm đánh giá thật là 1 nhưng dự đoán là 5) xuất hiện rất ít trong bộ dữ liệu quan sát được; trong khi đó theo cách dự đoán \hat{Y}_2 những điểm có độ lỗi nhỏ hơn (điểm đánh giá thật là 3 nhưng dự

đoán là 5) xuất hiện nhiều hơn trong bộ dữ liệu quan sát được; điều này làm cho độ lỗi của cách dự đoán \hat{Y}_1 thấp hơn cách dự đoán \hat{Y}_2 mặc dù cách dự đoán \hat{Y}_1 tệ hơn.



Hình 1.5: Đánh giá 2 mô hình dự đoán \hat{Y}_1 , \hat{Y}_2 dựa trên các mẫu quan sát được

Để khắc phục vấn đề thiên lệch dữ liệu tác giả Tobias Schnabel và các cộng sự [16] trong bài báo “Recommendations as Treatments: Debiasing Learning and Evaluation” tại hội nghị “ICML 2016”, đã đề xuất việc áp dụng phương pháp “Inverse propensity scoring” (IPS) vào quá trình huấn luyện và đánh giá mô hình. IPS hoạt động bằng cách đánh lại trọng số của các mẫu dựa trên điểm số xu hướng, theo cách giảm trọng số của các mẫu thường quan sát được, trong khi tăng trọng số của các mẫu hiếm gặp. Điều này sẽ giúp kiểm soát được vấn đề thiên lệch của dữ liệu.

1.3 Tổng quan

Phần còn lại của khóa luận sẽ được trình bày như sau:

- Chương 2 trình bày kiến thức nền tảng về “Matrix factorization”, “Gradient descent”, “Naive bayes” và “Logistic regression”.

- Chương 3 trình bày về độ đo IPS và ứng dụng của nó trong việc đánh giá và huấn luyện mô hình; đây là phần chính của khóa luận. Trong phần này gồm có hai phần nhỏ:
 - Độ đo “Self normalized inverse propensity scoring” (SNIPS).
 - Ước lượng ma trận xu hướng: nhóm chúng em trình bày về cách ước lượng ma trận xu hướng thông qua 2 mô hình “Naive bayes” và “Logistic regression”.
- Chương 4 trình bày về các thí nghiệm và các kết quả đạt được.
- Cuối cùng, tổng kết và các hướng phát triển sẽ được trình bày ở chương 5.

Chương 2


Kiến thức nền tảng

Trong chương này, đầu tiên nhóm chúng em trình bày về thuật toán “Matrix factorization” - thuật toán đề xuất sản phẩm bằng cách phân rã ma trận tương tác. Sau đó nhóm chúng em sẽ trình bày về thuật toán “Gradient descent” - thuật toán mà nhóm chúng em sẽ sử dụng để cực tiểu hóa hàm chi phí của “Matrix factorization”. Ngoài ra, nhóm chúng em còn trình bày về “Naive bayes” và “Logistic regression” - hai mô hình phân lớp mà nhóm chúng em sẽ sử dụng để tìm ma trận xu hướng trong IPS. Chương này, đặc biệt là về phần “Matrix factorization” cung cấp những kiến thức nền tảng để có thể hiểu rõ về những cải tiến mà nhóm em tìm hiểu ở chương kế tiếp.

2.1 “Matrix factorization”

“Matrix factorization” là một phương pháp thuộc nhóm lọc cộng tác (collaborative filtering), một nhóm các phương pháp tập trung vào mối quan hệ giữa các người dùng dựa trên đánh giá của các người dùng trong hệ thống. Phương pháp “Matrix factorization” sẽ phân tích ma trận tương tác $R \in \mathbb{R}^{m \times n}$ thành tích của hai ma trận $P \in \mathbb{R}^{m \times k}$ và $W \in \mathbb{R}^{k \times n}$ (hình 2.1 minh họa về việc phân tách ma trận tương tác R), trong đó: P và Q là ma trận đặc trưng của người dùng và sản phẩm; k là hyperparameter được

điều chỉnh trong quá trình huấn luyện mô hình, đại diện cho kích thước của đặc trưng tiềm ẩn.



Hình 2.1: Matrix Factorization. Ma trận tương tác R sẽ được phân rã thành ma trận đại diện cho người dùng P và đại diện cho sản phẩm Q

Ma trận tương tác R là ma trận thưa có kích thước là $m \times n$ chứa đánh giá của m người dùng đối với n sản phẩm có trong hệ thống. Đánh giá của người dùng u cho sản phẩm i trong ma trận tương tác sẽ được kí hiệu là $R_{u,i}$. Trong ma trận P hàng thứ u sẽ được kí hiệu là p_u và hàng thứ i trong ma trận Q sẽ được kí hiệu là q_i .

Các đặc trưng tiềm ẩn trong k mô tả sự liên quan giữa các người dùng và sản phẩm. Ví dụ như trong hệ thống đề xuất phim, các đặc trưng tiềm ẩn có thể là thể loại, ngôn ngữ, diễn viên hay bất kì các đặc trưng nào khác; hoặc có thể là bất cứ sự liên quan giữa người dùng và sản phẩm nào đó mà ta không thể giải thích được. Mỗi sản phẩm i trong ma trận sản phẩm Q sẽ mang đặc trưng ẩn ở một mức độ nào đó tương ứng với các hệ số trong véc-tơ q_i của nó, hệ số càng cao tương ứng với sản phẩm i mang đặc trưng đó càng lớn. Tương tự, mỗi người dùng u trong ma trận người dùng P sẽ thích các đặc trưng ẩn này theo một mức độ nào đó tương ứng với các hệ số trong véc-tơ p_u , hệ số càng cao tương ứng với người dùng u sẽ càng thích các bộ phim mang đặc trưng đó. Vì vậy, mục tiêu của chúng

ta là sẽ đề xuất cho người dùng u những sản phẩm i mang đặc trưng mà người dùng u thích, tương ứng với giá trị của p_u và q_i đều cao dẫn đến $p_u \times q_i$ càng cao.

2.2 “Gradient descent”

2.3 “Naive bayes”

2.4 “Logistic regression”

Chương 3

Phương pháp tìm hiểu

Chương này nhóm chúng em trình bày về những đóng góp của bài báo mà nhóm chúng em tìm hiểu được. Ở đây, nhóm chúng em tập trung vào việc xử lý vấn đề thiên lệch dữ liệu, bằng cách sử dụng độ đo khắc phục thiên lệch IPS trong quá trình đánh giá và huấn luyện mô hình. Sau đó, nhóm chúng em trình bày về “Self Normalized Inverse Propensity Scoring” (SNIPS) và so sánh với IPS để thấy được sự kết nối giữa IPS và SNIPS cũng như là những điểm lợi và hại của IPS so với SNIPS. Ngoài ra, nhóm chúng em còn trình bày về phương pháp ước lượng ma trận để phục vụ cho việc tính toán độ đo IPS và SNIPS.

3.1 Xem hệ thống gợi ý như một điều trị

Như đã trình bày ở ví dụ về thiên lệch dữ liệu, ta có thể thấy rằng ta chỉ đang quan sát được một phần của dữ liệu mà không thể thấy được toàn bộ sự thật, điều này bị ảnh hưởng bởi rất nhiều yếu tố tiềm ẩn. Giống như việc khi ta muốn xem xét một loại thuốc hay một phương pháp điều trị nhất định có hiệu quả như thế nào đối với bệnh nhân, giả sử ta tiến hành thử nghiệm phương pháp điều trị đó trên một nhóm bệnh nhân, sau đó ta theo dõi tình trạng bệnh của các bệnh nhân đó, và ta quan sát được sức khỏe của bệnh nhân có chuyển biến tích cực, liệu ta có thể kết luận

được rằng phương pháp điều trị đó có thật sự hiệu quả không? Nếu xem xét kĩ lưỡng, có thể rằng phương pháp điều trị của ta có lẽ khá đắt tiền nên chỉ những người có điều kiện kinh tế ổn định mới có xu hướng dễ tiếp xúc với phương pháp điều trị đó. Mà những người như vậy thì sẽ nhiều điều kiện thuận lợi để chăm sóc sức khỏe bản thân hơn, dẫn đến việc tình trạng bệnh của họ có chuyển biến tích cực hơn. Do đó việc kiểm tra được độ hiệu quả một phương pháp điều trị không hề đơn giản, người ta thường sử dụng các mô hình nhân quả. Nếu ta xem mỗi người dùng như một bệnh nhân, mỗi bộ phim ta gợi ý giống như một phương pháp điều trị hoặc một loại thuốc, ta sẽ quan tâm đến việc người dùng có phù hợp với bộ phim mà ta gợi ý hay không, phim được gợi ý có khiến người dùng thích thú hay không. Từ đó ta có thể thấy bài toán gợi ý và bài toán được đưa ra khá tương đồng nhau, do có ta cũng sử dụng ý tưởng giải quyết của các phương pháp nhân quả đối với bài toán xem xét hiệu quả điều trị để gợi ý sản phẩm.

Trong ví dụ về xem xét hiệu quả của một phương pháp điều trị, ta thấy được rằng ta cần phải kiểm soát cả những biến làm ảnh hưởng đến xu hướng mà bệnh nhân có thể tiếp cận được với điều trị đó để mô hình trở nên chính xác hơn, ví dụ như những đặc trưng về nhân khẩu học, thu nhập, mức sống, vị trí sống,... Tuy nhiên sẽ có rất nhiều biến ẩn như vậy mà ta khó có thể kiểm soát được. Do đó phương pháp nghịch đảo điểm xu hướng ra đời (Inverse propensity scoring - IPS) với ý tưởng rằng ta không cần phải kiểm soát trực tiếp những biến ẩn, mà chỉ cần kiểm soát được xu hướng nhận được điều trị của những bệnh nhân.

Trong bài toán gợi ý, với giả định rằng người dùng có thể đánh giá hoặc không đánh giá một phim mà họ đã xem, một đánh giá của người dùng dành cho một sản phẩm có thể xuất hiện hoặc không xuất hiện trong tập dữ liệu mà ta qua sát được. Ta có thể biểu diễn điều này thông qua ma trận quan sát O , trong đó các giá trị $O_{u,i} = 1$ tương ứng với đánh giá cho bộ phim i từ người dùng u được cung cấp tới hệ thống. Ta đặt $P_{u,i}$ là xác suất mà đánh giá $Y_{u,i}$ có thể quan sát được, hay $P_{u,i} = P(O_{u,i} = 1)$. $P_{u,i}$

được gọi là điểm xu hướng của đánh giá $Y_{u,i}$. Từ các đặc trưng mà ta đã quan sát được về các người dùng, các bộ phim và ma trận quan sát O , ta có thể dự đoán được điểm xu hướng của ma trận đánh giá Y . Phương pháp này sẽ được giới thiệu ở phần tiếp theo của khóa luận này.

O

	Horror	Romance	Drama
1	1		1
2	1	1	1
3	1		1
4	1		1
5	1		1
6	1		1
7	1		1
8	1		1
9	1		1

P

	Horror	Romance	Drama
1	p	p/10	p/2
2	p	p/10	p/2
3	p	p/10	p/2
4	p	p/10	p/2
5	p	p/10	p/2
6	p	p/10	p/2
7	p	p/10	p/2
8	p	p/10	p/2
9	p	p/10	p/2

Hình ảnh trên minh họa về việc biểu diễn ma trận quan sát O và ma

trận xu hướng P. Trong ma trận quan sát O các vị trí có giá trị là 1 đại diện cho đánh giá của người dùng với sản phẩm xuất hiện trong hệ thống, ma trận xu hướng P chứa xu hướng của các đánh giá tương ứng với khả năng ta quan sát được các đánh giá, những phim có số lượt đánh giá nhiều sẽ có điểm xu hướng cao.

3.2 “Inverse propensity scoring” (IPS)

Nhắc lại về phương pháp tính độ lỗi mà ta thường sử dụng, ta ký hiệu ma trận đánh giá mà ta quan sát được là Y, ma trận đánh giá mà ta cần phải dự đoán là \hat{Y} . Cụ thể, Y là ma trận đánh giá với các đánh giá bị thiếu, \hat{Y} là ma trận đánh giá sau khi được điền đầy đủ các đánh giá bị thiếu. Đầu tiên, mục tiêu của ta là đi tìm một hàm tính độ lỗi của \hat{Y} so với Y mà phản ánh được độ lỗi thật sự chỉ bằng tập dữ liệu quan sát được Y. Thông thường, hàm tính độ lỗi sẽ được biểu diễn như sau:

$$R(\hat{Y}) = \frac{1}{U \cdot I} \sum_{u=1}^U \sum_{i=1}^I \delta_{u,i}(Y, \hat{Y}) \quad (3.1)$$

Trong đó, δ là một hàm tính độ lỗi bất kì Nhưng vì ta chỉ có thể quan sát được một phần của toàn bộ đánh giá, do đó ta chỉ tính trung bình độ lỗi của các đánh giá quan sát được, ta tạm gọi hàm lỗi này là hàm lỗi ngây thơ(Naive), hàm lỗi này có công thức như sau:

$$R_{Naive}(\hat{Y}) = \frac{1}{|\{(u, i) : O_{u,i} = 1\}|} \sum_{(u,i):O_{u,i}=1}^I \delta_{u,i}(Y, \hat{Y}) \quad (3.2)$$

Sự ngây thơ của hàm lỗi này đã dẫn đến việc đánh giá mô hình bị sai ở ví dụ về thiên lệch lựa chọn trong phần giới thiệu. Do mẫu dữ liệu mà ta quan sát được không được phát sinh ngẫu nhiên theo phân phối đều từ dữ liệu thực tế mà bị tác động bởi thiên lệch lựa chọn. Đó là lý do tại sao

hàm lỗi ngây thơ lại có giá trị khác biệt so với độ lỗi thực tế, người ta gọi đây là một hàm lỗi bị lệch (bias), hay nói cách khác, kỳ vọng của hàm lỗi này khác với độ lỗi thực tế.

$$E_O[R_{Naive}(\hat{Y})] \neq R(\hat{Y})$$

Hiểu được vấn đề của hàm lỗi ngây thơ, tác giả đưa ra một hàm lỗi thay thế giúp giải quyết được vấn đề dữ liệu bị lệch. Phương pháp dựa trên một phương pháp thường được sử dụng trong các mô hình nhân quả, gọi là phương pháp nghịch đảo điểm xu hướng. Trong phạm vi của bài báo mà nhóm em tìm hiểu, tác giả tiến hành hai loại nghiên cứu là nghiên cứu quan sát và nghiên cứu thực nghiệm:

- Nghiên cứu thực nghiệm: trong nghiên cứu này, ta có thể điều khiển hệ thống gợi ý của ta bằng cách quyết định những sản phẩm nào sẽ được hiển thị đến người dùng, từ đó ta có thể biết được điểm xu hướng của nó.
- Nghiên cứu quan sát: trong nghiên cứu này, ta sẽ thu thập dữ liệu có sẵn từ một hệ thống đánh giá phim có sẵn, trong hệ thống này người dùng có quyền tự chọn những bộ phim họ xem và đánh giá. Do đó, ta không biết được điểm xu hướng mà cần phải tiến hành ước lượng nó. Phương pháp ước lượng này sẽ được trình bày cụ thể trong phần 3.3 thông qua các mô hình như Naive Bayes và Logistic Regression.

Áp dụng nghịch đảo điểm xu hướng đã được nghiên cứu bởi Little và Rubin 2000; Thompson, 2012; Imbens và Rubin, 2015 để sử dụng cho hàm lỗi của hệ thống gợi ý, ta định nghĩa công thức tính độ lỗi IPS như sau:

$$R_{IPS}(\hat{Y}|P) = \frac{1}{U \cdot I} \sum_{(u,i): O_{u,i}=1} \frac{\delta_{u,i}(Y, \hat{Y})}{P_{u,i}} \quad (3.3)$$

Về cơ bản, điểm xu hướng này luôn luôn lớn hơn 0 ở mọi cặp người dùng - sản phẩm để chắc chắn mỗi phần tử trong ma trận đánh giá Y đều

có thể được quan sát và tổng nghịch đảo các điểm xu hướng của các đánh giá mà ta quan sát được sẽ bằng với số lượng đánh giá của toàn bộ người dùng dành cho toàn bộ sản phẩm hay:

$$E_O \left[\sum_{(u,i): O_{u,i}=1} \frac{1}{P_{u,i}} \right] = U \cdot I \quad (3.4)$$

Bổ đề 3.2.1 (*Sự không thiên lệch của IPS*) Với mọi người dùng u và sản phẩm i , nếu điểm xu hướng $P_{u,i} \in (0, 1)$ và $P_{u,i} > 0$, thì $R_{IPS}(\hat{Y}|P)$ là một độ đo không thiên lệch của $R(\hat{Y})$, có nghĩa là kì vọng của $R_{IPS}(\hat{Y}|P)$ bằng với $R(\hat{Y})$

Chứng minh.

$$\begin{aligned} E_O \left[R_{IPS}(\hat{Y}|P) \right] &= \frac{1}{U \cdot I} \cdot \sum_{u=1}^U \sum_{i=1}^I \mathbb{E}_O \left[\frac{\delta_{u,i}(Y, \hat{Y})}{P_{u,i}} O_{u,i} \right] \\ &= \frac{1}{U \cdot I} \cdot \sum_{u=1}^U \sum_{i=1}^I \delta_{u,i} \\ &= R(\hat{Y}) \end{aligned} \quad (3.5)$$

3.3 “Self normalized inverse propensity scoring” (SNIPS)

$$\hat{R}_{SNIPS}(\hat{Y}|P) = \frac{\frac{1}{U \cdot I} \sum_{(u,i): O_{u,i}=1} \frac{\delta_{u,i}(Y, \hat{Y})}{P_{u,i}}}{\sum_{(u,i): O_{u,i}=1} \frac{1}{P_{u,i}}} U \cdot I = \frac{\sum_{(u,i): O_{u,i}=1} \frac{\delta_{u,i}(Y, \hat{Y})}{P_{u,i}}}{\sum_{(u,i): O_{u,i}=1} \frac{1}{P_{u,i}}} \quad (3.6)$$

3.4 Ước lượng ma trận xu hướng

Trước tiên, để hiểu được các phương pháp ước lượng xu hướng của một đánh giá hay nói các khác là khả năng mà một đánh giá được quan sát,

ta cần hiểu được các loại mất mát dữ liệu. Đầu tiên là MAR (Missing At Random), có nghĩa là sự mất mát dữ liệu này là ngẫu nhiên. Kiểu mất mát này là kiểu ta thường giả định trong học máy. Ở kiểu mất mát này, ta có thể ước lượng được giá trị bị thiếu thông qua các giá trị quan sát được. Ví dụ như trong nghiên cứu về thông tin nhân khẩu học, nếu ta giả định rằng giá trị thu nhập bị thiếu là ngẫu nhiên thì ta có thể ước lượng thu nhập bị thiếu dựa vào các thông tin ta quan sát được như độ tuổi, nghề nghiệp, nơi sống,..Tuy nhiên, một kiểu mất mát dữ liệu khác là MNAR (Missing Not At Random), ở kiểu mất mát này ta sẽ khó ước lượng được thu nhập bị thiếu vì các giá trị bị thiếu thường có một nguyên nhân nào đó, và nó mang một ý nghĩa nhất định. Trong trường hợp trên, có thể những người dùng có thu nhập cao có xu hướng hạn chế công khai thu nhập của bản thân, do đó những thu nhập bị thiếu có thể cao hơn phần thu nhập ta quan sát được rất nhiều do đó không thể ước lượng bằng các mô hình học máy thông thường. Còn một kiểu mất mát khác là MCAR (Missing Completely At Random), có nghĩa là sự mất mát dữ liệu là hoàn toàn ngẫu nhiên, các mẫu mà ta quan sát được có thể xem như những mẫu đại diện, do đó ta có thể xóa những mẫu có dữ liệu bị thiếu. Ta có thể tìm hiểu kỹ hơn về các vấn đề mất mát dữ liệu trong nghiên cứu của Little và Rubin, 2002. Xét nghiên cứu quan sát trên tập dữ liệu ML100K được cung cấp bởi Grouplens, ta dễ thấy các đánh giá bị thiếu không phải do ngẫu nhiên (MNAR) mà do thiên lệch lựa chọn của người dùng và của hệ thống gợi ý đã sử dụng. Do đó ta không biết được xu hướng của các đánh giá mà cần ước lượng xu hướng $P_{u,i}$ của mỗi đánh giá của người dùng u dành cho sản phẩm i sẽ được quan sát. Nói chung, xác suất một đánh giá ta có thể quan sát được có thể phụ thuộc vào các đặc trưng có thể quan sát được X (ví dụ như điểm số đánh giá dự đoán được hiển thị cho người dùng), các đặc trưng không thể quan sát được X^{hid} (ví dụ như sản phẩm đó có được giới thiệu bởi bạn bè của người dùng hay không), và đánh giá Y :

$$P_{u,i} = P(O_{u,i} = 1|X, X^{hid}, Y) \quad (3.7)$$

Do đó khi các đặc trưng có thể quan sát được đã được sử dụng để tính toán, ta có cơ sở để giả định rằng $O_{u,i}$ độc lập với ma trận dự đoán mới \hat{Y} nên nó độc lập với $\delta_{u,i}(Y, \hat{Y})$. Như đã đề cập ở trên, ta sử dụng hai phương pháp đơn giản để ước lượng ma trận xu hướng.

3.4.1 Ước lượng ma trận xu hướng thông qua Naive bayes

Để thực hiện được phương pháp Naive Bayes cho ước lượng ma trận xu hướng, ta cần phải giả định rằng sự phụ thuộc giữa các biến X , X_{hid} và các đánh giá khác là không đáng kể. Do đó công thức 3.7 được đơn giản thành $P(O_{u,i}|Y_{u,i})$ tương tự như Marlin và Zemel (2009). Ta có thể xem $Y_{u,i}$ như là những mẫu đánh giá mà ta quan sát được, khi đó ta chỉ cần ước lượng các điểm xu hướng cho những đánh giá quan sát được để tính toán IPS và SNIPS. Ta sử dụng Naive Bayes để ước lượng các xu hướng này như sau:

$$P(O_{u,i} = 1|Y_{u,i} = r) = \frac{P(Y = r|O = 1)P(O = 1)}{P(Y = r)} \quad (3.8)$$

Trong đó việc ước lượng hợp lý cực đại cho $P(Y = r|O = 1)$ và $P(O = 1)$ có thể được tính toán thông qua đếm số đánh giá quan sát được trong dữ liệu MNAR. Tuy nhiên, khi muốn ước lượng $P(Y = r) = P(Y = r|O = 1) + P(Y = r|O = 0)$, ta cần phải có một mẫu nhỏ MCAR. Phương pháp cụ thể để tìm tập nhỏ MNAR sẽ được trình bày ở phần thực nghiệm.

3.4.2 Ước lượng ma trận xu hướng thông qua Logistic regression

Một hướng tiếp cận khác để giải quyết việc ước lượng ma trận xu hướng là sử dụng hồi quy Logistic. Phương pháp này có ưu điểm là không yêu cầu một tập mẫu nhỏ MCAR. Cũng dựa trên công thức 3.7, nhưng mục tiêu của ta là tìm một bộ tham số ϕ sao cho ma trận quan sát O có thể độc lập với ma trận đặc trưng không quan sát được X^{hid} và Y . Nói cách khác, $P(O_{u,i} = 1|X, X^{hid}, Y) = P(O_{u,i}|X, \phi)$. Ở phương pháp này, ta giả định rằng tồn tại một bộ tham số $\phi = (\omega, \beta, \gamma)$ sao cho

$$P_{u,i} = \sigma(\omega^T X_{u,i} + \beta_i + \gamma_u) \quad (3.9)$$

Trong đó, $X_{u,i}$ là vector được vector hóa từ những thông tin quan sát được về các cặp người dùng, sản phẩm (ví dụ như thông tin nhân khẩu học của người dùng, bộ phim có được quảng cáo hay không), $\sigma(\cdot)$ là hàm sigmoid, β_i, γ_u là phần per-item và per-user

3.5 Phân rã ma trận kết hợp với IPS

\tilde{u}

Chương 4

Các kết quả thí nghiệm

Trong chương này, nhóm chúng em trình bày các kết quả thí nghiệm để đánh giá các đề xuất tìm hiểu được từ bài báo đã được nói ở chương trước. Bộ dữ liệu được dùng để tiến hành thí nghiệm là bộ COAT (bao gồm đánh giá của người dùng cho áo khoác), bộ Yahoo (bao gồm đánh giá của người dùng cho các bài hát), bộ Movielens 100K (bao gồm đánh giá của người dùng cho các bộ phim). Các kết quả thí nghiệm cho thấy khi dùng IPS đánh giá mô hình hoàn toàn khớp với hiệu suất thật và tốt hơn nhiều so với các độ đo đánh giá truyền thống. Các kết quả thí nghiệm cũng cho thấy mô hình được huấn luyện dựa trên độ đo IPS cũng cho kết quả tổng quát hóa tốt hơn trên các mức độ selection bias khác nhau.

- 4.1 Các thiết lập thí nghiệm
- 4.2 Đánh giá các phương pháp ước lượng điểm xu hướng
- 4.3 Đánh giá các phương pháp phân rã ma trận
- 4.4 Đánh giá hiệu suất trên dữ liệu thế giới thực

Chương 5

Tổng kết và hướng phát triển

Tài liệu tham khảo

Tiếng Anh

- [15] Marlin, Benjamin et al. “Collaborative Filtering and the Missing at Random Assumption”. In: *Proceedings of the Twenty-Third Conference on Uncertainty in Artificial Intelligence*. 2007, pp. 267–275.
- [16] Schnabel, Tobias et al. “Recommendations as Treatments: Debiasing Learning and Evaluation”. In: *ICML* 48 (2016), 1670—1679.