

HỆ THỐNG GỢI Ý SẢN PHẨM DỰA TRÊN MÔ HÌNH HỌC NHÂN QUẢ

(Causal learning models for building recommendation system)

Giáo viên hướng dẫn

ThS. Trần Trung Kiên
TS. Nguyễn Ngọc Thảo

Sinh viên thực hiện

Nguyễn Duy Vũ
Nguyễn Chiêu Bản

Nội dung báo cáo


1. Giới thiệu
2. Kiến thức nền tảng
3. Phương pháp tìm hiểu
4. Các kết quả thí nghiệm
5. Tổng kết và hướng phát triển

1. Giới thiệu

- Phát biểu bài toán
- Ý nghĩa của bài toán
- Thách thức
- Phương pháp giải quyết tìm hiểu

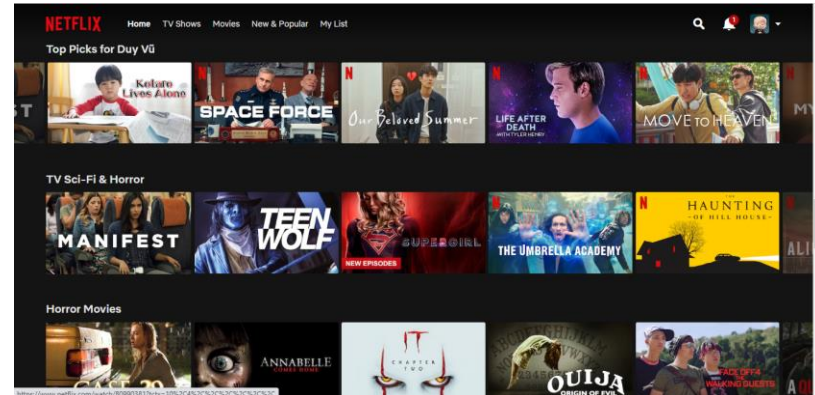
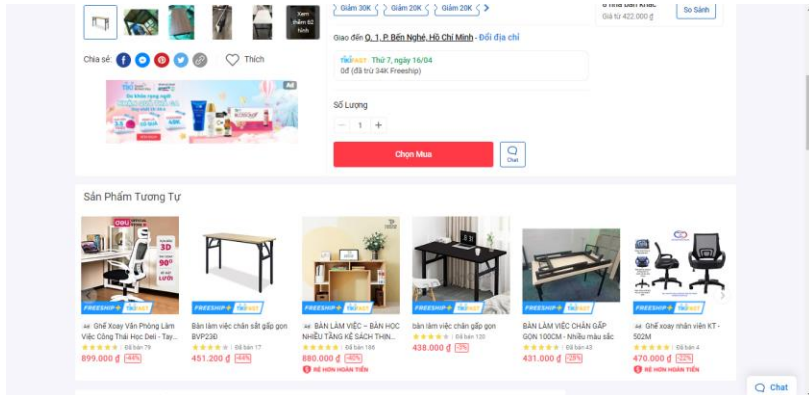
Phát biểu bài toán

- Đầu vào là dữ liệu về điểm đánh giá của các người dùng đối với các sản phẩm trong hệ thống (ngoài ra, còn có thể có thêm dữ liệu về thông tin của mỗi người dùng và mỗi sản phẩm).
- Yêu cầu: đề xuất các sản phẩm trong hệ thống mà phù hợp với sở thích của mỗi người dùng (để có thể đề xuất thì một cách làm phổ biến là dự đoán điểm đánh giá của người dùng đối với các sản phẩm mà người dùng chưa đánh giá).



Ý nghĩa của bài toán

- Giúp trải nghiệm của người dùng được cá nhân hóa, do các đề xuất được đưa ra thông qua các đánh giá trước đó của người dùng. Tiết kiệm thời gian cho người dùng trong việc lựa chọn sản phẩm, giúp cho người dùng tập trung hơn vào việc trải nghiệm dịch vụ.
- Đối với các công ty thì sẽ tăng lợi thế cạnh tranh bằng cách nâng cao sự hài lòng của khách hàng. Tăng doanh thu thông qua việc kích thích nhu cầu mua sắm của người dùng bằng các gợi ý sản phẩm.




Thách thức


Dữ liệu quan sát được trong bài toán đề xuất sản phẩm thường bị gặp vấn đề lớn về thiên lệch dữ liệu.

Thiên lệch dữ liệu: Dữ liệu quan sát được không được phát sinh từ phân bố đều. Bắt nguồn từ 2 nguyên nhân chính trong việc thu thập dữ liệu sau:

- Do người dùng tự chọn các bộ phim đánh giá.




(a) Randomly-selected items



(b) User-selected items

- Do hệ thống đề xuất chỉ chọn các bộ phim nào đó để hiển thị cho người dùng.

Ví dụ về thiên lệch



Ví dụ về thiên lệch

\hat{Y}_1
Pred Ratings (worse)

	Horror	Romance	Drama
Horror Lovers	5 5 5 5 5	5 5 5 5 5	3 3 3 3 3
Romance Lovers	5 5 5 5 5	5 5 5 5 5	3 3 3 3 3

Detailed description: This table shows predicted ratings for two groups of users. For Horror Lovers, the predicted rating is 5 for Horror and Romance, and 3 for Drama. For Romance Lovers, the predicted rating is 5 for Horror and Romance, and 3 for Drama. The ratings are consistent across both groups for each genre.

\hat{Y}_2
Pred Ratings (better)

	Horror	Romance	Drama
Horror Lovers	5 5 5 5 5	1 1 1 1 1	5 5 5 5 5
Romance Lovers	1 1 1 1 1	5 5 5 5 5	5 5 5 5 5

Detailed description: This table shows predicted ratings for two groups of users. For Horror Lovers, the predicted rating is 5 for Horror and Drama, and 1 for Romance. For Romance Lovers, the predicted rating is 1 for Horror and Romance, and 5 for Drama. The ratings are consistent across both groups for each genre.

Ví dụ về thiên lệch

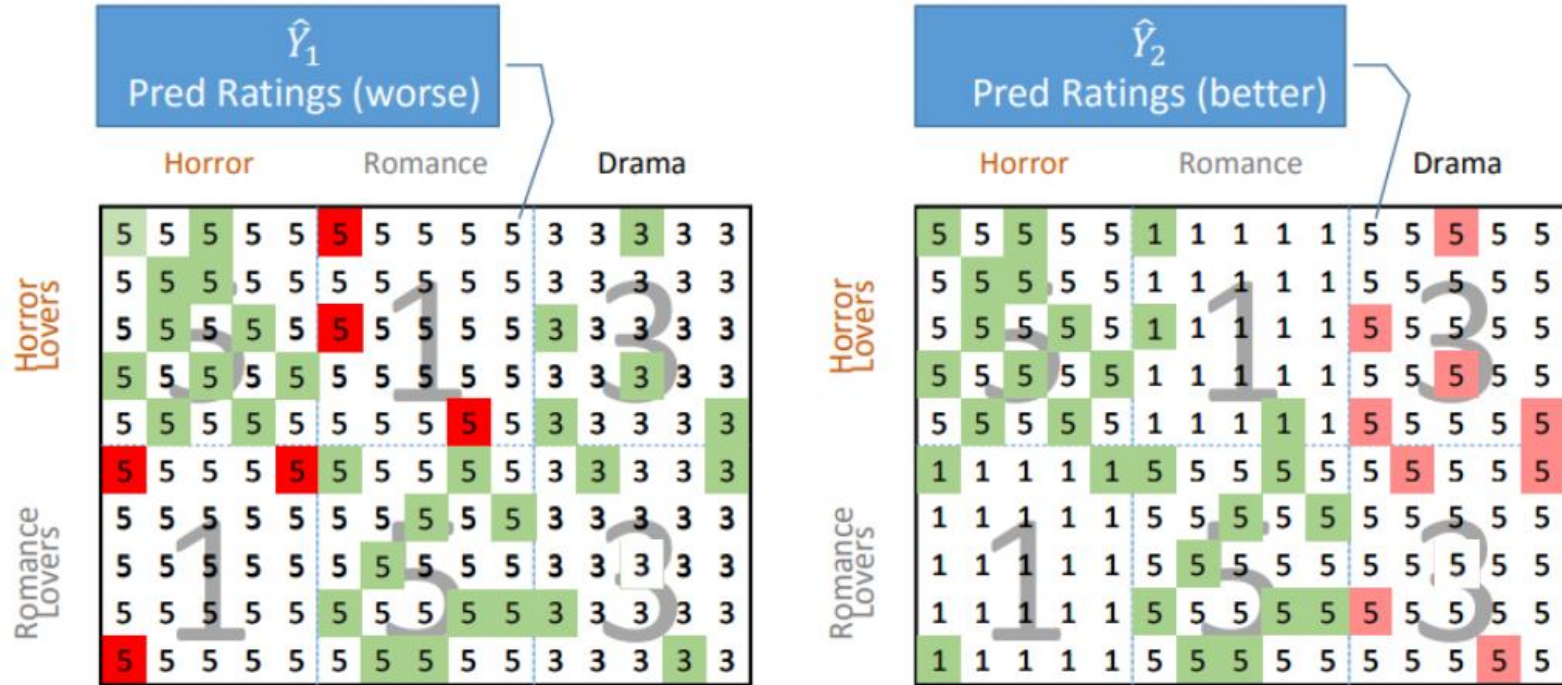
\hat{Y}_1
Pred Ratings (worse)

	Horror	Romance	Drama
Horror Lovers	5 5 5 5 5	5 5 5 5 5	3 3 3 3 3
Romance Lovers	5 5 5 5 5	5 5 5 5 5	3 3 3 3 3

\hat{Y}_2
Pred Ratings (better)

	Horror	Romance	Drama
Horror Lovers	5 5 5 5 5	1 1 1 1 1	5 5 5 5 5
Romance Lovers	1 1 1 1 1	5 5 5 5 5	5 5 5 5 5

Ví dụ về thiên lệch



Ta có thể thấy thì \hat{Y}_1 là mô hình dự đoán tệ hơn tuy nhiên khi đánh giá mô hình do số lượng mẫu dữ liệu dự đoán sai lệch nghiêm trọng này (dự đoán 5, giá trị thực là 1) ít dẫn đến độ lỗi của nó nhỏ và không tác động nhiều đến mô hình

Phương pháp giải quyết tìm hiểu


Để khắc phục vấn đề thiên lệch dữ liệu tác giả Tobias Schnabel và các cộng sự [1] trong bài báo **“Recommendations as Treatments: Debiasing Learning and Evaluation”** tại hội nghị “ICML 2016”, đã đề xuất việc áp dụng phương pháp **Chấm điểm theo nghịch đảo điểm xu hướng** (Inverse Propensity Scoring – IPS) vào quá trình huấn luyện và đánh giá mô hình. IPS hoạt động bằng cách đánh lại trọng số của các mẫu dựa trên điểm số xu hướng, theo cách giảm trọng số của các mẫu thường quan sát được, trong khi tăng trọng số của các mẫu hiếm gặp. Điều này sẽ giúp kiểm soát được vấn đề thiên lệch của dữ liệu.

2. Kiến thức nền tảng

- Matrix Factorization
- Naive Bayes
- Logistic Regression

Matrix Factorization

Matrix factorization (phân rã ma trận) là một phương pháp thuộc nhóm lọc cộng tác. Mô hình này sẽ phân tích ma trận tương tác của user – item Y thành tích hai ma trận V và W, với V là ma trận đại diện cho người dùng và W là ma trận đại diện cho sản phẩm.



Matrix Factorization

Khi đó điểm đánh giá của người dùng u cho sản phẩm i sẽ được tính toán bằng:

$$\widehat{Y}_{u,i} = v_u \times w_i^T + A$$

Mô hình sẽ được huấn luyện bằng cách cực tiểu hóa trung bình bình phương sai số giữa đánh giá dự đoán và đánh giá thực trên toàn bộ tập dữ liệu quan sát được. Hàm mục tiêu được định nghĩa như sau:

$$\operatorname{argmin}_{V,W,A} \sum_{(u,i) \in \mathcal{K}} (Y_{u,i} - \widehat{Y}_{u,i})^2 + \lambda (||V||_F^2 + ||W||_F^2 + A)$$

3. Phương pháp tìm hiểu

- Nghịch đảo điểm xu hướng (IPS)
- Ước lượng ma trận xu hướng
- Phân rã ma trận kết hợp IPS

Điểm xu hướng (Propensity Score)

- Theo giả định rằng người dùng có thể không đánh giá một bộ phim mà họ đã xem, do đó một đánh giá của người dùng u dành cho sản phẩm i có thể không xuất hiện trong tập dữ liệu
- Ta đặt $P_{u,i}$ là xác suất mà đánh giá $Y_{u,i}$ có thể quan sát được (hay $O_{u,i} = 1$)
- $P_{u,i} = P(O_{u,i} = 1)$
- $P_{u,i}$ được gọi là xu hướng (propensity) của đánh giá $Y_{u,i}$

Ma trận quan sát O

	Horror				Romance				Drama				
1	0	1	0	1	0	0	0	0	0	1	0	0	0
0	1	1	0	0	0	0	0	0	0	0	0	0	0
0	1	0	1	0	1	0	0	0	0	1	0	0	0
1	0	0	0	0	0	0	0	0	0	0	1	0	0
0	1	0	1	0	0	0	1	0	1	0	0	0	1
1	0	0	0	1	1	0	0	1	0	1	0	0	1
0	0	0	0	0	0	0	1	0	1	0	0	0	0
0	0	0	0	0	0	1	0	0	0	0	1	0	0
0	0	0	0	0	1	0	0	0	1	1	0	0	0
1	0	0	0	0	0	1	1	0	0	0	0	0	1

Ma trận xu hướng P

	Horror	Romance	Drama
p	p	p/10	p/2
p/10	p/10	p	p/2

Nghịch đảo điểm xu hướng

Inverse propensity scoring (IPS)

Để tính độ chính xác của ma trận đánh giá dự đoán \hat{Y} đối với ma trận đánh giá Y :

$$\hat{R}_{naive}(\hat{Y}) = \frac{1}{|\{(u, i) : O_{u,i} = 1\}|} \sum_{(u,i): O_{u,i}=1} \delta_{u,i}(Y, \hat{Y})$$

Người ta muốn tăng trọng số của những đánh giá có khả năng xuất hiện thấp, do đó ta nhân độ lỗi của mỗi đánh giá mà ta quan sát được với nghịch đảo điểm xu hướng của nó:

$$\hat{R}_{IPS}(\hat{Y}|P) = \frac{1}{U \cdot I} \sum_{(u,i): O_{u,i}=1} \frac{\delta_{u,i}(Y, \hat{Y})}{P_{u,i}}$$

Ước lượng ma trận xu hướng

- Xác suất một đánh giá ta có thể quan sát được có thể phụ thuộc vào các đặc trưng có thể quan sát được X đặc trưng quan sát được của người dùng và sản phẩm, các đặc trưng không thể quan sát được X^{hid} (ví dụ như sản phẩm đó có được giới thiệu bởi bạn bè của người dùng hay không), và đánh giá Y

$$P_{u,i} = P(O_{u,i} = 1 \mid X, X^{hid}, Y)$$

- Ta sử dụng hai phương pháp: Naive Bayes và Hồi quy Logistic

Ước lượng thông qua Naive Bayes

Giả sử rằng sự phụ thuộc của X và X^{hid} là không đáng kể, khi đó công thức được đơn giản thành $P(O_{u,i}=1 | Y_{u,i}=r)$, ta sử dụng Naive Bayes để ước lượng các xu hướng này như sau:

$$P(O_{u,i} = 1 | Y_{u,i} = r) = \frac{P(Y = r | O = 1)P(O = 1)}{P(Y = r)}$$

Trong đó việc ước lượng khá dễ cực đại cho $P(Y=r | O=1)$ và $P(O=1)$ có thể được tính toán thông qua đếm số đánh giá quan sát được trong dữ liệu MNAR. Tuy nhiên, khi muốn ước lượng $P(Y = r) = P(Y=r | O=1) + P(Y=r | O=0)$, ta cần phải có một mẫu nhỏ MCAR. Phương pháp cụ thể để tìm tập nhỏ MNAR sẽ được trình bày ở phần thực nghiệm

Ước lượng thông qua hồi quy logistic

Một hướng tiếp cận khác để giải quyết việc ước lượng ma trận xu hướng là sử dụng hồi quy Logistic. Phương pháp này có ưu điểm là không yêu cầu một tập mẫu nhỏ MCAR.

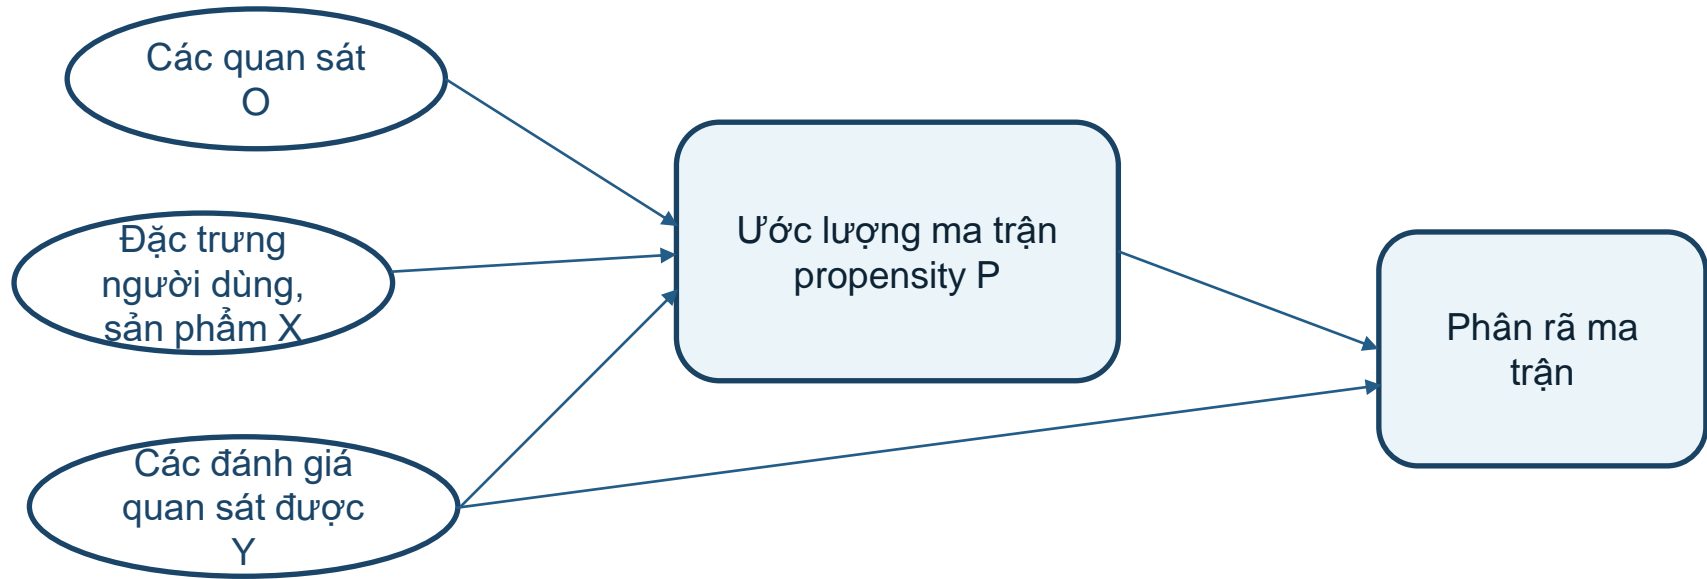
Ở phương pháp này, ta giả định rằng tồn tại một bộ tham số $\varphi = (\omega, \beta, \gamma)$ sao cho

$$P_{u,i} = \sigma \left(w^T X_{u,i} + \beta_i + \gamma_u \right)$$

Trong đó,

- $X_{u,i}$ là vector được vector hóa từ những thông tin quan sát được về các cặp người dùng, sản phẩm.
- $\sigma(\cdot)$ là hàm sigmoid.
- β_i, γ_u là phần lần lượt là vector đại diện cho sản phẩm và người dùng

Quá trình huấn luyện



Mục tiêu huấn luyện

Mục tiêu của quá trình huấn luyện dựa trên tập dữ liệu quan sát được là:

$$\operatorname{argmin}_{V,W,A} \sum_{(u,i) \in \kappa} \frac{(Y_{u,i} - \widehat{Y}_{u,i})^2}{P_{u,i}} + \lambda \left(\|V\|_F^2 + \|W\|_F^2 + A \right)$$

4. Các kết quả thí nghiệm

- Kết quả cài đặt của nhóm trên tập dữ liệu thế giới thực và so sánh kết quả với bài báo
- Ảnh hưởng của việc dữ liệu bị thiên lệch tới việc học của MF và MF-IPS
- Ảnh hưởng của việc ước lượng propensity tới việc học của MF-IPS

Đánh giá hiệu suất trên dữ liệu thế giới thực

Dữ liệu: 2 tập dữ liệu đều có một tập kiểm tra riêng được phát sinh theo phân phối đều để kiểm tra hiệu suất của mô hình.

Tập dữ liệu Yahoo R3: chứa đánh giá của người dùng cho các bài hát.

- Tập dữ liệu huấn luyện chứa hơn 300k đánh giá của 15400 người dùng.
- Tập dữ liệu kiểm tra chứa đánh giá của 5400 người dùng. Tập dữ liệu này được thu thập bằng cách cho người dùng đánh giá 10 bài hát ngẫu nhiên
- Ma trận xu hướng được ước lượng thông qua phương pháp Naive Bayes. Dữ liệu MCAR sẽ được lấy từ 5% dữ liệu kiểm tra.

Đánh giá hiệu suất trên dữ liệu thế giới thực

Tập dữ liệu Coat Shopping: chứa đánh giá của người dùng cho các áo khoác

- Tác giả tạo ra một giao diện web mua sắm đơn giản, sau đó chọn chiếc áo khoác họ muốn mua nhất rồi đánh giá 24 chiếc áo khoác do họ tự lựa chọn và 16 chiếc được chọn ngẫu nhiên theo phân bố đều trên thang điểm 5
- Ma trận xu hướng được ước lượng thông qua phương pháp Logistic Regression, dựa trên thuộc tính của người dùng và thuộc tính của sản phẩm. Mô hình Logistic Regression được huấn luyện bằng cách sử dụng các cặp thuộc tính của người dùng và sản phẩm làm đặc trưng đầu vào, và sử dụng cross-validation để đánh giá mô hình huấn luyện này

Kết quả trên tập thể giới thực

Kết quả của nhóm

	Yahoo		Coat	
	MAE	MSE	MAE	MSE
MF-IPS	0.796	0.976	0.904	1.197
MF	1.183	1.899	0.916	1.205

Kết quả của bài báo

	YAHOO		COAT	
	MAE	MSE	MAE	MSE
<i>MF-IPS</i>	0.810	0.989	0.860	1.093
<i>MF-Naive</i>	1.154	1.891	0.920	1.202

Thí nghiệm 1

- Dữ liệu: tập dữ liệu ML100k chứa đánh giá cho 1683 bộ phim bởi 944 người dùng
- Tạo ra tập dữ liệu tổng hợp từ ML100k, điền đầy đủ các đánh giá còn trống của ma trận đánh giá sử dụng phương pháp phân rã ma trận thông thường.
- Tuy nhiên, sau khi điền đầy đủ đánh giá thì hầu hết các đánh giá đều có số điểm cao.
- Ta tiến hành điều chỉnh các giá trị của đánh giá theo phân phối $[p_1, p_2, p_3, p_4, p_5]$ cho các đánh giá từ 1 đến 5

Thí nghiệm 1

Ta tìm phân phối xác suất trên như sau:

- Với những đánh giá có giá trị là 4 hoặc 5, xu hướng của nó sẽ bằng k
- Với các đánh giá có giá trị nhỏ hơn 4, xu hướng của đánh giá đó sẽ tương ứng với $k\alpha^{4-r}$, với mỗi α , k là một tập sao cho kỳ vọng của số lượng đánh giá ta quan sát được bằng với 5% của cả ma trận.
- Khi $\alpha = 0.25$, ta có được phân phối xác suất biên của tập dữ liệu MNAR là $[0.06, 0.10, 0.25, 0.42, 0.17]$, trong khi phân phối thực sự của dữ liệu này là $[0.06, 0.11, 0.27, 0.35, 0.21]$

Thí nghiệm 1

Khi đó, với $\alpha = 0,25$, ta đo độ chính xác của mô hình theo 5 cách dự đoán sau:

- REC_ONES: ma trận dự đoán \hat{Y} giống với ma trận Y , ngoại trừ n đánh giá 1 sao sẽ được chuyển thành 5 sao với n là tổng số đánh giá 5 sao
- REC_FOURS: giống phương pháp trên, sử dụng với các đánh giá bằng 4
- ROTATE: khi $Y_{u,i} \geq 2$, thì $\hat{Y}_{u,i} = Y_{u,i} - 1$, khi $Y_{u,i} = 1$ thì $\hat{Y} = 5$
- SKEWED: dự đoán $\hat{Y}_{u,i}$ tuân theo phân phối chuẩn với $\mu = Y_{u,i}$ và $\sigma = (6 - Y_{u,i})/2$
- COARSENEED: dự đoán $\hat{Y}_{u,i} = 3$ nếu $Y_{u,i} \leq 3$, $\hat{Y}_{u,i} = 4$ với các trường hợp còn lại

Kết quả thí nghiệm 1



	MAE			
	True	IPS	SNIPS	Naive
REC_ONES	0.102	0.102 ± 0.007	0.102 ± 0.007	0.011 ± 0.001
REC_FOURS	0.026	0.026 ± 0.000	0.026 ± 0.000	0.173 ± 0.001
ROTATE	2.579	2.581 ± 0.031	2.579 ± 0.012	1.168 ± 0.003
SKEWED	1.306	1.304 ± 0.012	1.304 ± 0.009	0.912 ± 0.002
COARSENEED	1.320	1.314 ± 0.015	1.318 ± 0.005	0.387 ± 0.002

	DCG@50			
	True	IPS	SNIPS	Naive
REC_ONES	30.76	30.64 ± 0.75	30.66 ± 0.74	153.07 ± 2.13
REC_FOURS	52.00	51.98 ± 0.41	52.08 ± 0.58	313.48 ± 2.36
ROTATE	12.90	13.00 ± 0.85	12.99 ± 0.83	1.38 ± 0.09
SKEWED	24.59	24.55 ± 0.92	24.58 ± 0.93	54.87 ± 1.03
COARSENEED	46.45	46.45 ± 0.53	46.44 ± 0.70	293.27 ± 1.99

Thí nghiệm 1

Ta thử nghiệm với các tham số $\alpha \in (0, 1]$, quan sát độ chính xác trung bình của mô hình thông qua 5 cách dự đoán được nêu bên trên thông qua 50 lần thử

Kết quả thí nghiệm 1



5. Tổng kết và hướng phát triển

Tài liệu tham khảo

[1] Tobias Schnabel, Adith Swaminathan, Ashudeep Singh, Navin Chandak, and Thorsten Joachims. 2016. Recommendations as treatments: Debiasing learning and evaluation. In ICML (JMLR Workshop and Conference Proceedings), Vol. 48. 1670–1679